



**UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO
ESCUELA NACIONAL DE ESTUDIOS
SUPERIORES UNIDAD MORELIA**



A: 8 DE ENERO DE 2026

**PROYECTO FINAL
CALIDAD DEL VINO
ANÁLISIS DE ESTADÍSTICA MULTIVARIADA**

**PRESENTA:
LUIS ALBERTO GARCÍA OROZCO**

**PROFESOR:
DRA. ADRIANA HAYDEÉ CONTRERAS PERUYERO**

**5° SEMESTRE/ASIGNATURA:
ESTADÍSTICA MULTIVARIADA**

**LICENCIATURA EN TECNOLOGÍAS PARA LA
INFORMACIÓN EN CIENCIAS**

Resumen

Brief summary of the problem, approach, and main results. Keep it short and precise.

1. Introduction

Según la Organización Internacional de la Viña y el Vino (OIV, 2023), la calidad del vino se define como el conjunto de características organolépticas, fisicoquímicas y sensoriales que lo distinguen y determinan su aceptabilidad por parte del consumidor. Esta definición abarca no solo los atributos perceptibles mediante los sentidos (vista, olfato, gusto), sino también las propiedades químicas subyacentes que determinan las características del vino y su potencial de envejecimiento. La evaluación de la calidad enológica constituye un elemento fundamental tanto para productores como para consumidores, ya que permite establecer estándares de producción y facilitar la toma de decisiones en un mercado cada vez más competitivo y globalizado.

El presente trabajo tiene por objetivo analizar la calidad del vino de manera multivariante, empleando técnicas estadísticas avanzadas que permitan comprender las relaciones entre las diferentes propiedades químicas y su influencia sobre la percepción de calidad. Para tal efecto, se han considerado once variables fisicoquímicas que describen composición ácida, contenido sulfúrico, densidad, pH, concentración de azúcares residuales y grado alcohólico, entre otras características determinantes en el perfil enológico del vino. Adicionalmente, se incorpora la variable categórica que distingue el tipo de vino (tinto o blanco), permitiendo un análisis comparativo entre ambas categorías.

A nivel de datos, se ha utilizado una base de datos proveniente del repositorio de aprendizaje automático de la Universidad de California en Irvine (UCI Machine Learning Repository), específicamente el conjunto de datos denominado ‘Wine Quality’ que contiene información sobre vinos verdes portugueses, tanto tintos como blancos, provenientes de la región norte de Portugal. Este dataset constituye un referente ampliamente utilizado en estudios de minería de datos y aprendizaje automático aplicados a la enología, dado que representa de manera fiel las características químicas que determinan la calidad del vino en condiciones reales de producción. El análisis multivariante de estos datos permitirá identificar patrones, agrupamientos y relaciones que contribuyan a una comprensión más profunda de los factores que determinan la calidad enológica, proporcionando información valiosa tanto para la industria vitivinícola como para la investigación científica en el área de análisis de alimentos y bebidas.

Variables Numéricas

- **fixed acidity**: Concentración de ácidos no volátiles (principalmente tartárico y málico). Afecta la frescura y longevidad del vino.
- **volatile acidity**: Concentración de ácidos volátiles (principalmente acético). Valores elevados indican defectos enológicos.
- **citric acid**: Concentración de ácido cítrico. Contribuye a la acidez total y estabilidad del color.
- **residual sugar**: Azúcares no fermentados que permanecen en el vino. Determina el nivel de dulzor.
- **chlorides**: Concentración de cloruros. Niveles elevados pueden indicar contaminación o excesiva salinidad.
- **free sulfur dioxide**: Fracción libre de SO_2 . Actúa como antioxidante y antimicrobiano.
- **total sulfur dioxide**: Concentración total de SO_2 . Límite legal controlado por normativas de cada país.
- **density**: Densidad del vino respecto al agua. Indicador del contenido de alcohol y azúcares.
- **pH**: Nivel de acidez en escala logarítmica. Afecta color, sabor y estabilidad del vino.
- **sulphates**: Concentración de sulfatos. Nutriente para levaduras durante la fermentación.
- **alcohol**: Porcentaje de alcohol etílico. Resultado de la fermentación de azúcares por levaduras.
- **quality**: Calificación sensorial otorgada por panel de catadores. Variable de respuesta del modelo.

Variable Categórica

- **type**: Distingue entre vinos tintos y blancos. Refleja diferencias en variedades de uva, procesos de vinificación y características sensoriales.

2. Metodología

La metodología empleada en este estudio comprende un conjunto de técnicas estadísticas multivariantes aplicadas de manera secuencial para explorar, modelar e interpretar las relaciones entre las propiedades fisicoquímicas del vino y su calidad percibida. A continuación se describe cada etapa del proceso analítico.

2.1. Descripción de los Datos y Variables

El conjunto de datos utilizado comprende inicialmente 6497 observaciones de vinos portugueses, con un total de 13 variables que incluyen 11 variables fisicoquímicas numéricas, una variable categórica binaria (tipo de vino) y una variable de respuesta ordinal (calidad). Las variables fisicoquímicas abarcan indicadores de composición ácida (acidez fija, acidez volátil, ácido cítrico), contenido sulfúrico (dióxido de azufre libre y total), propiedades físicas (densidad, pH) y composición química adicional (azúcar residual, cloruros, sulfatos, alcohol). La variable calidad representa la evaluación sensorial media otorgada por un panel de catadores, escala ordinal que varía de 3 a 9 puntos. La variable categórica distingue entre vinos tintos (1599 observaciones, 24.6 %) y vinos blancos (4898 observaciones, 75.4 %).

Preprocesamiento de datos: Se verificó la ausencia de valores faltantes en todas las variables del dataset. Posteriormente, se realizó un análisis de valores atípicos mediante diagramas de caja (boxplots), lo cual requirió la normalización de variables y la aplicación del método z-score para estandarización. Se identificaron y eliminaron 540 observaciones atípicas mediante el método del rango intercuartílico (IQR), representando el 8.31 % del total de datos. El conjunto de datos resultante, libre de valores atípicos, comprende 5957 observaciones disponibles para el análisis posterior.

Organización del análisis: Para permitir comparaciones entre tipos de vino, el conjunto de datos se dividió en tres versiones: el dataset *general* (combinando vinos tintos y blancos), el dataset de vinos tintos (*red*) y el dataset de vinos blancos (*white*). Esta separación permite identificar variables relevantes específicas para cada tipo de vino, así como realizar análisis comparativos entre categorías.

2.2. Análisis Exploratorio Multivariado

El análisis exploratorio inicial tuvo como propósito identificar patrones, relaciones y particularidades en los datos antes de aplicar técnicas inferenciales. Se construyeron diagramas de caja para las variables numéricas en sus versiones original, normalizada y z-estandarizada, permitiendo observar la distribución y detectar valores atípicos. Se generaron diagramas de dispersión y boxplots condicionados por el tipo de vino, permitiendo identificar diferencias sistemáticas en la composición química entre vinos tintos y blancos.




Figura 1: Boxplots de los atributos del vino tinto y blanco estandarizados (Z-score).




Figura 2: Corrplots de los atributos del *general* dataset, *red* dataset y *white* dataset

2.3. Regresión Lineal Múltiple

Se ajustaron modelos de regresión lineal múltiple para cada dataset (general, red, white), con la calidad del vino como variable respuesta y las once variables fisicoquímicas como predictores. La selección de variables significativas se realizó mediante el procedimiento stepwise utilizando el método `ols_step_both_aic`, que optimiza el Criterio de Información de Akaike (AIC) mediante selección hacia adelante y hacia atrás.

Modelo General: El modelo resultante presenta un coeficiente de determinación ajustado $R^2_{adj} = 0,290$. Las variables significativas seleccionadas fueron: contenido alcohólico, acidez volátil, sulfatos, azúcar residual, dióxido de azufre libre y total, typewhite, densidad, pH y acidez fija. La variable dicotómica typewhite se incluyó para distinguir entre vinos tintos y blancos.

Modelo Vinos Tintos (Red): El modelo presenta un coeficiente de determinación ajustado $R^2_{adj} = 0,379$, superior al modelo general. Las variables seleccionadas fueron: contenido alcohólico, sulfatos, acidez volátil, dióxido de azufre total y libre, pH y ácido cítrico. A diferencia del modelo general, este incluye ácido cítrico y excluye azúcar residual, densidad, acidez fija y la variable typewhite (no necesaria al trabajar únicamente con vinos tintos).

Modelo Vinos Blancos (White): El modelo presenta un coeficiente de determinación ajustado $R^2_{adj} = 0,283$. Las variables seleccionadas fueron: contenido alcohólico, acidez volátil, azúcar residual, dióxido de azufre libre, densidad, sulfatos, pH, acidez fija y cloruros. A diferencia del modelo general, incluye cloruros pero excluye dióxido de azufre total y la variable typewhite.

Comparación de Modelos: El mayor poder explicativo del modelo de vinos tintos ($R^2 = 0.372$) sugiere que las variables fisicoquímicas tienen mayor capacidad predictiva de la calidad en el tipo de vino tinto. Las diferencias en las variables seleccionadas entre modelos indican que los factores químicos que influyen en la percepción de calidad varían según el tipo de vino. El modelo de vinos tintos no requiere las variables de densidad, acidez fija ni azúcar residual, mientras que el modelo de vinos blancos no incluye la variable dióxido de azufre total pero sí requiere cloruros.

	Estimate	t value	Pr(> t)	Significance
(Intercept)	1.329974e+02	7.875786	3.996731e-15	Yes
alcohol	1.992215e-01	9.317917	1.635733e-20	Yes
'volatile acidity'	-1.445187e+00	-15.692958	2.062734e-54	Yes
sulphates	8.858313e-01	9.682959	5.175991e-22	Yes
'residual sugar'	7.209835e-02	10.811296	5.417686e-27	Yes
'free sulfur dioxide'	6.656150e-03	7.783589	8.258833e-15	Yes
'total sulfur dioxide'	-1.204106e-03	-3.549286	3.892619e-04	Yes
typewhite	-4.215543e-01	-6.822321	9.845697e-12	Yes
density	-1.328004e+02	-7.767070	9.397688e-15	Yes
pH	6.113373e-01	6.272774	3.796570e-10	Yes
'fixed acidity'	1.037171e-01	5.980552	2.353180e-09	Yes

	Estimate	t value	Pr(> t)	Significance
(Intercept)	4.429326732	8.628896	1.795635e-17	Yes
alcohol	0.288687128	16.570006	4.753275e-56	Yes
sulphates	1.700463523	10.556443	4.831777e-25	Yes
'volatile acidity'	-1.044690943	-6.455966	1.519609e-10	Yes
'total sulfur dioxide'	-0.002962838	-0.017447	6.223566e-05	Yes
pH	-0.645621058	-4.446220	9.491675e-06	Yes
'citric acid'	-0.401410583	-2.911064	3.663992e-03	Yes
'free sulfur dioxide'	0.003827944	1.635079	1.022768e-01	No

	Estimate	t value	Pr(> t)	Significance
(Intercept)	2.071353e+02	8.994465	3.390117e-19	Yes
alcohol	1.212288e-01	4.094497	4.302691e-05	Yes
'volatile acidity'	-1.795913e+00	-15.427830	2.073744e-52	Yes
'residual sugar'	9.947887e-02	11.394829	1.095037e-29	Yes
'free sulfur dioxide'	5.714188e-03	7.565007	4.646528e-14	Yes
density	-2.080029e+02	-8.913145	6.996130e-19	Yes
sulphates	7.431125e-01	6.947242	4.239846e-12	Yes
pH	8.760063e-01	7.650345	2.420920e-14	Yes
'fixed acidity'	1.195999e-01	5.132632	2.973632e-07	Yes
chlorides	-1.893257e+00	-1.810526	7.027871e-02	No

Figura 3: Tablas de la significancia de los regresores de los modelos del *general* dataset, *red* dataset y *white* dataset

Intervalos de Confianza: Se calcularon intervalos de confianza del 95 % para los coeficientes de cada modelo. En el modelo general, se observó que los intervalos del intercepto y la densidad presentaban rangos amplios (superiores a 60) mientras que los demás coeficientes tenían intervalos inferiores a 0.5, lo cual indicaba problemas de multicolinealidad. En el modelo de vinos tintos, todos los intervalos fueron razonables. En el modelo de vinos blancos, el patrón observado en el modelo general se repitió pero con rangos aún más amplios (superiores a 80).

	Estimate	t value	Pr(> t)	Significance
(Intercept)	99.8930304258091	166.101860544519	66.208301187096	
alcohol	0.157307996036068	0.24113480534134	0.0838269890040655	
'volatile acidity'	-1.62571912028683	-1.26465394990776	0.361065170379071	
sulphates	0.70649034872501	1.06517222933155	0.358681800606536	
'residual sugar'	0.0590250805737277	0.0851716101080442	0.0261485295351165	
'free sulfur dioxide'	0.004979742251173	0.0083325983757656	0.9033528162660356	
'total sulfur dioxide'	-0.0018691646351679	-0.000539046733971484	0.0013301179015903	
typewhite	-0.542686076815286	-0.3004226160216991	0.242263460193595	
density	-166.318442267588	-99.2823566136905	67.0360856538972	
pH	0.420282602065864	0.802392088462323	0.382109486396459	

	2.5 %	97.5 %	range
(Intercept)	3.40063225179721	5.41532938375384	2.01469713195664
alcohol	0.255800916304828	0.324134364612303	0.0683334483074757
sulphates	1.42134851203293	2.04839881798931	0.627021305956385
'volatile acidity'	-1.40435632725975	-0.779168671438552	0.625187655821196
'total sulfur dioxide'	-0.00321177882143082	-0.00108095808307474	0.00213082073835608
pH	-0.91699712269922	-0.347778689361431	0.569218428655612
'citric acid'	-0.709604978571066	-0.177840571979181	0.531764406591885

	2.5 %	97.5 %	range
(Intercept)	171.538376546829	259.917964940103	88.3795883927376
alcohol	0.0620384578820393	0.178130672449239	0.116092214567199
'volatile acidity'	-2.03579962530216	-1.57999979580634	0.455799829495816
'residual sugar'	0.08959218720036823	0.11944889848608	0.0335270184363975
'free sulfur dioxide'	0.00423208344678252	0.00719447537604025	0.0029623918925773
density	-261.610537870642	-172.123070064937	89.4874678057042
sulphates	0.538230620261851	0.95760870368147	0.419378083419619
pH	0.679945014131803	1.12530745070554	0.445362436573739
'fixed acidity'	0.0807254379636947	0.171086584438886	0.0903611464749909

Figura 4: Tablas de los intervalos de confianza de los regresores de los modelos del *general* dataset, *red* dataset y *white* dataset **después** de los cambios

2.4. Validación de Supuestos del Modelo

La validación de supuestos se realizó para cada uno de los tres modelos de regresión, verificando las condiciones necesarias para la validez de las inferencias estadísticas.

Multicolinealidad: Se evaluó mediante el Factor de Inflación de Varianza (VIF) y matrices de correlación. En el modelo general, las variables azúcar residual ($VIF = 11.08$) y densidad ($VIF = 28.34$) presentaron valores elevados, indicando multicolinealidad severa. Se decidió eliminar la variable densidad, lo cual provocó que las variables pH ($p = 0.07$) y acidez fija ($p = 0.5$) perdieran significancia estadística. Tras eliminar también la acidez fija, los intervalos de confianza se estrecharon y el modelo mejoró su estabilidad. En el modelo de vinos tintos, todos los valores VIF fueron inferiores a 5, indicando ausencia de multicolinealidad. En el modelo de vinos blancos, las variables azúcar residual ($VIF = 15.02$), alcohol ($VIF = 11.16$) y densidad ($VIF = 36.96$) presentaron valores elevados; tras eliminar densidad, el modelo mejoró significativamente.

[illegible]

Figura 5: Tablas de los vaolors VIF de los regresores de los modelos del *general* dataset, *red* dataset y *white* dataset **antes** de los cambios

	vif(model)	scale		vif(model)	scale		vif(model)	scale
alcohol	1.365017	Low				alcohol	1.338638	Low
`volatile acidity`	1.807034	Low	alcohol	1.203373	Low	`volatile acidity`	1.031919	Low
sulphates	1.375477	Low	sulphates	1.197360	Low	`residual sugar`	1.455074	Low
`residual sugar`	1.558745	Low	`volatile acidity`	1.685124	Low	`free sulfur dioxide`	1.183822	Low
`free sulfur dioxide`	2.213906	Low	`total sulfur dioxide`	1.054184	Low	sulphates	1.041918	Low
`total sulfur dioxide`	3.785799	Low	pH	1.474588	Low	pH	1.306517	Low
type	3.794881	Low	`citric acid`	2.151292	Low	`fixed acidity`	1.250985	Low
pH	1.192041	Low						

Figura 6: Tablas de los valores VIF de los regresores de los modelos del *general* dataset, *red* dataset y *white* dataset **después** de los cambios

Normalidad de Residuos: Se evaluó mediante el test de Shapiro-Wilk y gráficos Q-Q. Los tres modelos presentaron rechazos de la hipótesis de normalidad (modelo general: $p = 1.13\text{e-}15$; modelo red: $p = 3.39\text{e-}5$; modelo white: $p = 8.32\text{e-}15$). Sin embargo, los estadísticos W fueron muy cercanos a 1 en los tres casos (poco más de 0.99) y los gráficos Q-Q mostraron que los residuos seguían razonablemente la línea diagonal, con desviaciones leves principalmente en las colas. Se concluyó que el rechazo de normalidad se debe a la alta sensibilidad del test con muestras grandes, por lo que se asume cumplimiento aproximado del supuesto para propósitos del análisis.




Figura 7: Gráficos QQ de los residuos de los modelos del *general* dataset, *red* dataset y *white* dataset

Homocedasticidad: Se evaluó mediante el test de Breusch-Pagan. Los tres modelos presentaron rechazos de la hipótesis nula de homocedasticidad: modelo general (BP = 124.83, df = 8, $p < 2.2e-16$), modelo red (BP = 50.18, df = 6, $p = 4.34e-9$), modelo white (BP = 67.36, df = 7, $p = 5.03e-12$). Se intentó transformar el modelo mediante logaritmo de la variable respuesta (logModel), pero los tests continuaron rechazando homocedasticidad con valores similares. Por lo tanto, se reporta que los tres modelos presentan heterocedasticidad, lo cual debe considerarse en la interpretación de resultados.




Figura 8: Gráficos de valores residuales vs valores predichos del modelo de *general* dataset

Autocorrelación: Se evaluó mediante el test de Durbin-Watson. En los tres modelos no se detectó presencia de autocorrelación de residuos, cumpliendo este supuesto del modelo de regresión.

Análisis de Varianza (ANOVA): Se realizó ANOVA para cada modelo, verificando que todos los componentes del modelo son estadísticamente significativos. Los F-values y sus correspondientes p-valores confirman que los modelos son apropiados para explicar la variabilidad en la calidad del vino.

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	significance
alcohol	1	880.781998	880.7819976	1663.281388	7.386281e-321	Yes
`volatile acidity`	1	202.100213	202.1002127	381.648947	1.993869e-82	Yes
sulphates	1	52.829405	52.8294052	99.763808	2.618389e-23	Yes
`residual sugar`	1	53.865753	53.8657527	101.720862	9.910029e-24	Yes
`free sulfur dioxide`	1	17.364007	17.3640068	32.790440	1.076679e-08	Yes
`total sulfur dioxide`	1	35.200077	35.2000769	66.472331	4.290312e-16	Yes
type	1	4.501858	4.5018577	8.501373	3.562042e-03	Yes
pH	1	2.951778	2.9517778	5.574180	1.825927e-02	Yes
Residuals	5948	3149.732426	0.5295448	NA	NA	NA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	significance
alcohol	1	201.450431	201.4504309	542.370805	2.036395e-100	Yes
sulphates	1	60.223809	60.2238093	162.142299	4.528050e-35	Yes
`volatile acidity`	1	18.575438	18.5754375	50.011186	2.499753e-12	Yes
`total sulfur dioxide`	1	6.701440	6.7014404	18.042481	2.315482e-05	Yes
pH	1	3.605432	3.6054322	9.707009	1.876183e-03	Yes
`citric acid`	1	3.981337	3.9813371	10.719069	1.088513e-03	Yes
Residuals	1289	478.767668	0.3714257	NA	NA	NA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	significance
alcohol	1	672.707579	672.7075788	1196.361071	1.642458e-233	Yes
`volatile acidity`	1	157.045850	157.0458504	279.294522	6.200790e-61	Yes
`residual sugar`	1	74.574817	74.5748167	132.625840	2.798713e-30	Yes
`free sulfur dioxide`	1	38.946993	38.9469934	69.264370	1.119684e-16	Yes
sulphates	1	11.640369	11.6403694	20.701543	5.503910e-06	Yes
pH	1	7.576200	7.5761996	13.473715	2.446409e-04	Yes
`fixed acidity`	1	5.155755	5.1557553	9.169132	2.474807e-03	Yes
Residuals	4653	2616.357586	0.5622948	NA	NA	NA

Figura 9: Analisis ANOVA de los modelos del *general* dataset, *red* dataset y *white* dataset

2.5. Análisis de Componentes Principales (PCA)

Se aplicó Análisis de Componentes Principales a cada dataset (*general*, *red*, *white*) para reducir la dimensionalidad e identificar las dimensiones subyacentes que caracterizan la composición química del vino. Los datos fueron previamente estandarizados mediante z-score para asegurar que todas las variables contribuyeran equitativamente.

Selección del número de componentes: Se utilizaron múltiples criterios para determinar el número óptimo de componentes: scree plot porcentual con porcentaje de aportación de cada componente, scree plot con eigenvalues y línea horizontal en 1 (regla de Kaiser), procedimiento de análisis paralelo de Horn, y función nScree. Los cuatro métodos convergieron en la selección de 4 componentes principales para los tres datasets.

Interpretación de Componentes - Dataset General:

- **PC1 (varianzaexpained):** Dominado por dióxido de azufre (libre y total), cloruros y acidez volátil. Representa el ‘perfil de conservación’ del vino.
- **PC2:** Dominado por densidad, alcohol y azúcar residual. Representa el ‘cuerpo’ del vino.
- **PC3:** Dominado por acidez fija, ácido cítrico y pH. Representa el ‘perfil de acidez’ del vino.

- **PC4:** Dominado por sulfatos, calidad y pH. Representa características complementarias de frescura y percepción de calidad.

Interpretación de Componentes - Dataset Red (Vinos Tintos):

- **PC1:** Similar al PC3 del dataset general, dominado por acidez fija, ácido cítrico, pH y densidad. Representa el ‘perfil de acidez’ específico de vinos tintos.
- **PC2:** Dominado por densidad, alcohol, calidad y cloruros. Representa la ‘cuerpo y calidad’ del vino tinto.
- **PC3:** Dominado por dióxido de azufre (libre y total). Representa el ‘contenido sulfúrico’ del vino tinto.
- **PC4:** Similar al PC4 del dataset general, dominado por sulfatos, azúcar residual y pH.

Interpretación de Componentes - Dataset White (Vinos Blancos):

- **PC1:** Similar al PC2 del dataset general, dominado por densidad, alcohol, azúcar residual y dióxido de azufre total. Representa el ‘cuerpo’ característico de vinos blancos.
- **PC2:** Similar al PC3 del dataset general, dominado por acidez fija, ácido cítrico y pH. Representa el ‘perfil de acidez’ de vinos blancos.
- **PC3:** Dominado por dióxido de azufre libre, calidad, acidez volátil y ácido cítrico.
- **PC4:** Dominado por sulfatos, acidez volátil, cloruros y dióxido de azufre libre.




Figura 10: Scree plots percentuales de *general* dataset, *red* dataset y *white* dataset




Figura 11: Scree plots con autovalores y pruebas para escoger no. componentes de *general* dataset, *red* dataset y *white* dataset




Figura 12: Loading plots de las componentes 1 y 2 de *general* dataset, *red* dataset y *white* dataset



Figura 13: Bibiplots de sample de *general* dataset, *red* dataset y *white* dataset

	PC1	PC2	PC3	PC4
<i>fixed acidity</i>	-0.270494626223958	-0.203780434960143	-0.533229367012903	0.0809790096448826
<i>volatile acidity</i>	-0.396315341069109	-0.0554860372346399	0.234573541242664	0.117210372317431
<i>citric acid</i>	0.147037931343929	-0.114282477927954	-0.600386923385959	-0.111490855189694
<i>residual sugar</i>	0.267702251267979	-0.387283585934528	0.0570358483237917	-0.107688000610594
<i>chlorides</i>	-0.414356427552831	-0.250353838877846	0.0188509533970499	-0.0814100956949489
<i>free sulfur dioxide</i>	0.393464674925842	-0.177028910299214	0.122648385719549	-0.282299392827914
<i>total sulfur dioxide</i>	0.435054569146966	-0.213189140670959	0.126179010530277	-0.113172386371306
<i>density</i>	-0.152020645147188	-0.547724533057302	-0.00368372679785468	-0.161244407818352
<i>pH</i>	-0.205903612554148	0.133009253675476	0.410776120130573	-0.474262049193839
<i>sulphates</i>	-0.288761927350948	-0.0478188290283669	-0.123456886291717	-0.595591759058555
<i>alcohol</i>	0.00375496932245713	0.504269096608167	-0.174441316119467	-0.0814467566151728
<i>quality</i>	0.108627145451923	0.280378843712143	-0.226236726063756	-0.494227988344281

	PC1	PC2	PC3	PC4
<i>fixed acidity</i>	0.525086053687676	0.0678417686609312	-0.068391943498631	0.067529812768069
<i>volatile acidity</i>	-0.264989564070983	0.344557411752098	-0.188056990799762	-0.298160320012901
<i>citric acid</i>	0.480580197147521	-0.120624563866768	0.137411749348767	0.19118528390119
<i>residual sugar</i>	0.144547157867339	0.0728858382720853	0.267319724207279	-0.594833928749467
<i>chlorides</i>	0.150045473834265	0.339195248677788	-0.058730132273009	-0.28153010751338
<i>free sulfur dioxide</i>	-0.12086853738972	0.0822786403591008	0.65930970914119	0.0814433353566792
<i>total sulfur dioxide</i>	-0.0714202200234631	0.22965341009087	0.635153514971318	0.121135223195825
<i>density</i>	0.37293267499218	0.358961858823566	-0.0396464259785834	-0.282571804093359
<i>pH</i>	-0.41366740003597	-0.102515069460743	0.00410324976013658	-0.340240659769194
<i>sulphates</i>	0.188800787832606	-0.296569652424137	0.137972860250433	-0.381131373295984
<i>alcohol</i>	-0.0221482401761406	-0.500721398469695	0.0614846182595133	-0.153437695822995
<i>quality</i>	0.116852407261319	-0.451899037696094	0.0604254390280685	-0.22623039260339

	PC1	PC2	PC3	PC4
<i>fixed acidity</i>	0.138275434234077	-0.596736070885325	-0.0918403139915675	-0.104524250767866
<i>volatile acidity</i>	-0.00250182185223968	0.0766808277448987	0.469733004030743	0.349732971597039
<i>citric acid</i>	0.107147477335449	-0.348973546172809	-0.435251971509375	-0.205646180498759
<i>residual sugar</i>	0.397390207585406	0.00972494671080205	-0.0413874088297787	0.325514319828134
<i>chlorides</i>	0.300963934272397	0.0661751876930527	0.226083966633877	-0.32732425582456
<i>free sulfur dioxide</i>	0.27585904251104	0.254652345185664	-0.385769217324169	0.335996494728307
<i>total sulfur dioxide</i>	0.383797995032026	0.220333943255378	-0.178510415247414	0.154520817000739
<i>density</i>	0.495923413805943	-0.00102935101228899	0.0306307152913563	-0.0117545276485901
<i>pH</i>	-0.103337117846362	0.579564988299921	-0.0301977891233063	-0.271300236896458
<i>sulphates</i>	0.0443110240329608	0.231917502189995	-0.263042562310243	-0.537148969702104
<i>alcohol</i>	-0.441474660236116	-0.0238685144300575	-0.16369107042614	0.197077025793594
<i>quality</i>	-0.20979454083714	0.0901272094806973	-0.500124929063668	0.271089934518119

Figura 14: Tabla de loadings de los 4 componentes de *general* dataset, *red* dataset y *white* dataset

2.6. Análisis de Clustering

Se aplicó análisis de clustering tanto jerárquico como no jerárquico (k-means) a cada dataset, utilizando únicamente las variables que resultaron significativas en los modelos de regresión finales. Los datos fueron estandarizados mediante z-score y, para agilizar ciertos procesos computacionales, se trabajó con muestras de 1000 observaciones.

Métodos de Clustering Jerárquico: Se aplicaron cuatro métodos de enlace (linkage): enlace simple (single linkage), enlace completo (complete linkage), enlace promedio (average

linkage) y método de Ward (ward.D2). Se calcularon los coeficientes de correlación (cophenetic correlation) para evaluar la calidad de cada dendrograma, permitiendo comparar los métodos y seleccionar el más apropiado para cada dataset.

Determinación del número de clusters: Se utilizó la función NbClust con los datos muestreados ($n = 1000$) para determinar el número óptimo de clusters recomendado. Los resultados fueron: 2 clusters para el dataset general, 4 clusters para el dataset red, y 3 clusters para el dataset white.

Selección del método de enlace: Se seleccionó el método de clustering jerárquico con el mayor coeficiente de correlación para cada dataset, plots múltiples comparando los cuatro métodos.

Clustering No Jerárquico (k-means): Se aplicó el algoritmo k-means utilizando el número de clusters determinado por NbClust para cada dataset. Este método complementa el análisis jerárquico y proporciona una partición alternativa de los datos.




Figura 15: Dendrograma con mejor coeficiente de correlación *general* dataset, *red* dataset y *white* dataset



Figura 16: Resultados de Kmenans para *general* dataset, *red* dataset y *white* dataset

3. Discusión de Resultados

La discusión de los resultados integra los hallazgos de las diferentes técnicas estadísticas aplicadas, estableciendo conexiones entre los resultados y proporcionando una interpretación unificada de los factores que determinan la calidad del vino.

3.1. Resultados del Modelo de Regresión

Los modelos de regresión lineal múltiple identificaron las variables fisicoquímicas con efecto significativo sobre la calidad del vino, revelando tanto similitudes como diferencias importantes entre los tipos de vino. El contenido alcohólico presenta coeficientes positivos en los tres modelos, confirmando su importancia universal como predictor de calidad. La acidez volátil presenta coeficientes negativos consistentes, indicando que concentraciones elevadas de ácido

acético reducen significativamente la calidad percibida en ambos tipos de vino. Los sulfatos muestran efectos positivos en todos los modelos, sugiriendo su contribución a la frescura y complejidad aromática.

La diferencia más notable entre modelos radica en el poder explicativo: el modelo de vinos tintos ($R^2 = 0.372$) explica considerablemente más varianza que los modelos general ($R^2 = 0.289$) y white ($R^2 = 0.284$). Esta diferencia sugiere que las características fisicoquímicas tienen mayor capacidad predictiva de la calidad en vinos tintos, posiblemente debido a que los procesos de vinificación para tintos (maceración con hollejos) producen mayor variabilidad en los compuestos químicos que influyen en la percepción de calidad.

Las variables eliminadas por multicolinealidad (densidad, acidez fija) presentan correlaciones fuertes con otros predictores, lo cual indica que su información está parcialmente capturada por las variables retenidas. La densidad, por ejemplo, está fuertemente correlacionada con el contenido alcohólico ($r = -0.73$), por lo que su exclusión del modelo no implica pérdida sustancial de información predictiva.

El rechazo de homocedasticidad en los tres modelos mediante el test de Breusch-Pagan indica que la varianza de los errores no es constante, lo cual puede afectar la eficiencia de las estimaciones pero no invalida las conclusiones sobre la significancia de las variables. La transformación logarítmica de la variable respuesta no resolvió el problema, sugiriendo que la heterocedasticidad es una característica intrínseca de los datos enológicos.

3.2. Resultados del Análisis de Componentes Principales

El análisis de componentes principales reveló estructuras subyacentes diferenciadas según el tipo de vino, proporcionando interpretaciones complementarias a los modelos de regresión. En el dataset general, el primer componente captura el ‘perfil de conservación’ (dióxido de azufre y cloruros), mientras que el segundo componente captura el ‘cuerpo’ (densidad, alcohol, azúcar residual). Esta estructura bimodal refleja la tensión entre la estabilidad química y las características gustativas del vino.

La comparación entre datasets revela que los vinos tintos mantienen una estructura de componentes más similar al patrón general, mientras que los vinos blancos presentan una configuración diferente donde el ‘cuerpo’ (PC1) lidera la varianza. Esta diferencia sugiere que las características que más varían entre vinos blancos son su contenido de alcohol, azúcar

y densidad, mientras que en vinos tintos la acidez y el pH juegan un papel más diferenciador.

La identificación de 4 componentes principales en los tres datasets, explicando una porción sustancial de la varianza total, confirma que las 11 variables originales pueden reducirse efectivamente a un número menor de dimensiones interpretables. Esta reducción facilita la visualización de patrones y puede utilizarse para clasificación, control de calidad y optimización de procesos enológicos.

3.3. Resultados del Análisis de Clustering

El análisis de clustering identificó diferentes números de grupos naturales según el tipo de vino: 2 clusters para el dataset general, 4 clusters para vinos tintos y 3 clusters para vinos blancos. Esta diferencia en el número óptimo de clusters sugiere que la estructura natural de agrupamiento varía según el tipo de vino, con los vinos tintos presentando mayor heterogeneidad interna que requiere más grupos para capturar las diferencias.

La utilización de las variables regresoras del modelo final para el clustering permite establecer conexiones directas entre los factores predictivos de calidad y los grupos naturales identificados. Los clusters resultantes pueden interpretarse como perfiles de vino con características químicas distintivas y, presumiblemente, diferentes niveles de calidad percibida.

La combinación de métodos jerárquicos y no jerárquicos (k-means) proporciona robustez a los resultados, permitiendo validar los clusters identificados mediante diferentes algoritmos. El método de Ward generalmente produce los clusters más compactos y bien separados, mientras que k-means proporciona una partición alternativa que puede revelar patrones diferentes en los datos.

4. Conclusiones

El análisis multivariante del dataset Wine Quality permite extraer conclusiones relevantes tanto desde la perspectiva estadística como enológica, contribuyendo a una mejor comprensión de las relaciones entre las propiedades fisicoquímicas del vino y su evaluación sensorial.

Los modelos de regresión lineal múltiple revelaron que la calidad del vino puede explicarse significativamente mediante variables fisicoquímicas como contenido alcohólico (relación positiva), acidez volátil (relación negativa) y sulfatos (relación positiva). El modelo de vinos

tintos presentó mayor poder explicativo ($R^2 = 0.372$) que los modelos general y de vinos blancos, sugiriendo que las características químicas tienen mayor capacidad predictiva en este tipo de vino. Las diferencias en las variables seleccionadas entre modelos indican que los factores químicos que influyen en la percepción de calidad varían según el tipo de vino.

La validación de supuestos reveló ausencia de multicolinealidad severa (tras eliminaciones de variables problemáticas), violación de homocedasticidad en los tres modelos, y normalidad aproximada de residuos a pesar del rechazo estadístico. Estos hallazgos deben considerarse en la interpretación de resultados, aunque no invalidan las conclusiones principales sobre las variables con efecto significativo.

El análisis de componentes principales identificó 4 componentes principales en los tres datasets, revelando estructuras subyacentes diferenciadas: ‘perfil de conservación’, ‘cuerp’, ‘perfil de acidez’ y características complementarias de frescura. Las diferencias entre vinos tintos y blancos en la interpretación de componentes sugieren estrategias de control de calidad específicas por tipo.

El clustering identificó 2, 4 y 3 grupos naturales para los datasets general, red y white respectivamente, utilizando las variables significativas de cada modelo de regresión. La concordancia parcial entre factores predictivos y clusters fortalece la validez de los hallazgos, proporcionando herramientas prácticas para clasificación y control de calidad en la industria vitivinícola.

En conclusión, las técnicas estadísticas multivariantes demuestran su utilidad para comprender las relaciones entre composición química y calidad del vino. La combinación de métodos supervisados (regresión) y no supervisados (PCA, clustering) proporciona perspectivas complementarias que permiten tanto predecir la calidad como descubrir patrones subyacentes en los datos. La comparación entre tipos de vino revela diferencias importantes que deben considerarse en cualquier estrategia de control de calidad específica.

Referencias

- [1] Organización Internacional de la Viña y el Vino (OIV). (2023). *Definición de calidad del vino*. París, Francia: OIV.
- [2] UCI Machine Learning Repository. (s.f.). *Wine Quality Dataset*. University of California, Irvine. Recuperado de <https://archive.ics.uci.edu/ml/datasets/wine+quality>
- [3] Cortez, P., Cerdeira, A., Almeida, F., Matos, T., y Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4), 547-553.