

LUIS ALBERTO GARCÍA OROZCO

ESTADÍSTICA MULTIVARIADA

5TO. SEMESTRE

CALIDAD DEL VINO ANÁLISIS DE ESTADÍSTICA MULTIVARIADA

PROYECTO FINAL

INTRODUCCIÓN

Según la Organización Internacional de la Viña y el Vino (OIV, 2023), la calidad del vino se define como el conjunto de características organolépticas, fisicoquímicas y sensoriales que lo distinguen y determinan su aceptabilidad por parte del consumidor. Esta definición abarca no solo los atributos perceptibles mediante los sentidos (vista, olfato, gusto), sino también las propiedades químicas subyacentes que determinan las características del vino y su potencial de envejecimiento. La evaluación de la calidad enológica constituye un elemento fundamental tanto para productores como para consumidores, ya que permite establecer estándares de producción y facilitar la toma de decisiones en un mercado cada vez más competitivo y globalizado.

El presente trabajo tiene por objetivo analizar la calidad del vino de manera multivariante, empleando técnicas estadísticas avanzadas que permitan comprender las relaciones entre las diferentes propiedades químicas y su influencia sobre la percepción de calidad. Para tal efecto, se han considerado once variables fisicoquímicas que describen composición ácida, contenido sulfúrico, densidad, pH, concentración de azúcares residuales y grado alcohólico, entre otras características determinantes en el perfil enológico del vino. Adicionalmente, se incorpora la variable categórica que distingue el tipo de vino (tinto o blanco), permitiendo un análisis comparativo entre ambas categorías.

METODOLOGÍA

La metodología empleada en este estudio comprende un conjunto de técnicas estadísticas multivariantes aplicadas de manera secuencial para explorar, modelar e interpretar las relaciones entre las propiedades fisicoquímicas del vino y su calidad percibida. A continuación se describe cada etapa del proceso analítico

1. Descripción de los Datos y Variables

➤ Preprocesamiento de datos:

Originalmente eran 6497 datos y 13 variables (una de respuesta, otra categórica y las demás numéricas)



Se verificó la ausencia de valores faltantes

Posteriormente, se realizó un análisis de valores atípicos mediante diagramas de caja (boxplots)

Se identificaron y eliminaron 540 observaciones atípicas mediante el método del rango intercuartílico (IQR) (el 8.31% del total de datos). El conjunto de datos resultante, libre de valores atípicos, comprende 5957 observaciones disponibles para el análisis posterior

2. Análisis Exploratorio Multivariado

Boxplots of Cleaned Red Wine Attributes standardized (Z-score)



3. Regresión Lineal Múltiple

Modelo General: El modelo resultante presenta un coeficiente de determinación ajustado $R^2_{adj} = 0,290$. Las variables significativas seleccionadas fueron: contenido alcohólico, acidez volátil, sulfatos, azúcar residual, dióxido de azufre libre y total, typewhite, densidad, pH y acidez fija. La variable dicotómica typewhite se incluyó para distinguir entre vinos tintos y blancos.

Modelo Vinos Tintos (Red): El modelo presenta un coeficiente de determinación ajustado $R^2_{adj} = 0,379$, superior al modelo general. Las variables seleccionadas fueron: contenido alcohólico, sulfatos, acidez volátil, dióxido de azufre total y libre, pH y ácido cítrico. A diferencia del modelo general, este incluye ácido cítrico y excluye azúcar residual, densidad, acidez fija y la variable typewhite (no necesaria al trabajar únicamente con vinos tintos).

Modelo Vinos Blancos (White): El modelo presenta un coeficiente de determinación ajustado $R^2_{adj} = 0,283$. Las variables seleccionadas fueron: contenido alcohólico, acidez volátil, azúcar residual, dióxido de azufre libre, densidad, sulfatos, pH, acidez fija y cloruros. A diferencia del modelo general, incluye cloruros pero excluye dióxido de azufre total y la variable typewhite.

Comparación de Modelos: El mayor poder explicativo del modelo de vinos tintos ($R^2 = 0.372$) sugiere que las variables fisicoquímicas tienen mayor capacidad predictiva de la calidad en el tipo de vino tinto. Las diferencias en las variables seleccionadas entre modelos indican que los factores químicos que influyen en la percepción de calidad varían según el tipo de vino. El modelo de vinos tintos no requiere las variables de densidad, acidez fija ni azúcar residual, mientras que el modelo de vinos blancos no incluye la variable dióxido de azufre total pero sí requiere cloruros.

4. Validación de Supuestos del Modelo

Multicolinealidad: Se evaluó mediante el Factor de Inflación de Varianza (VIF) y matrices de correlación. En el modelo general, las variables azúcar residual (VIF = 11.08) y densidad (VIF = 28.34) presentaron valores elevados, indicando multicolinealidad severa

[illegible]

Figura 5: Tablas de los vaolors VIF de los regresores de los modelos del *general* dataset, *red* dataset y *white* dataset **antes** de los cambios

	vif(model)	scale		vif(model)	scale		vif(model)	scale
alcohol	1.365017	Low				alcohol	1.338638	Low
`volatile acidity`	1.807034	Low	alcohol	1.203373	Low	`volatile acidity`	1.031919	Low
sulphates	1.375477	Low	sulphates	1.197360	Low	`residual sugar`	1.455074	Low
`residual sugar`	1.558745	Low	`volatile acidity`	1.685124	Low	`free sulfur dioxide`	1.183822	Low
`free sulfur dioxide`	2.213906	Low	`total sulfur dioxide`	1.054184	Low	sulphates	1.041918	Low
`total sulfur dioxide`	3.785799	Low	pH	1.474588	Low	pH	1.306517	Low
type	3.794881	Low	`citric acid`	2.151292	Low	`fixed acidity`	1.250985	Low
pH	1.192041	Low						

Figura 6: Tablas de los valores VIF de los regresores de los modelos del *general* dataset, *red* dataset y *white* dataset **después** de los cambios

Normalidad de Residuos: Se evaluó mediante el test de Shapiro-Wilk y gráficos Q-Q. Los tres modelos presentaron rechazos de la hipótesis de normalidad (modelo general: $p = 1.13e-15$; modelo red: $p = 3.39e-5$; modelo white: $p = 8.32e-15$). Se concluyó que el rechazo de normalidad se debe a la alta sensibilidad del test con muestras grandes, por lo que se asume cumplimiento aproximado del supuesto para propósitos del análisis.




Figura 7: Gráficos QQ de los residuos de los modelos del *general* dataset, *red* dataset y *white* dataset

Homocedasticidad: Se evaluó mediante el test de Breusch-Pagan. Los tres modelos pre sentaron rechazos de la hipótesis nula de homocedasticidad: modelo general (BP = 124.83, df = 8, $p < 2.2e-16$), modelo red (BP = 50.18, df = 6, $p = 4.34e-9$), modelo white (BP = 67.36, df = 7, $p = 5.03e-12$). Por lo tanto, se reporta que los tres modelos presentan heterocedasticidad, lo cual debe considerarse en la interpretación de resultados.




Figura 8: Gráficos de valores residuales vs valores predichos del modelo de *general* dataset

4. Validación de Supuestos del Modelo

Autocorrelación: Se evaluó mediante el test de Durbin-Watson. En los tres modelos no se detectó presencia de autocorrelación de residuos, cumpliendo este supuesto del modelo de regresión

Análisis de Varianza (ANOVA): Se realizó ANOVA para cada modelo, verificando que todos los componentes del modelo son estadísticamente significativos. Los F-values y sus correspondientes p-valores confirman que los modelos son apropiados para explicar la varia bilidad en la calidad del vino

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	significance
alcohol	1	880.781998	880.7819976	1663.281388	7.386281e-321	Yes
'volatile acidity'	1	202.100213	202.1002127	381.648947	1.993869e-82	Yes
sulphates	1	52.829405	52.8294052	99.763808	2.618389e-23	Yes
'residual sugar'	1	53.865753	53.8657527	101.720862	9.910029e-24	Yes
'free sulfur dioxide'	1	17.364007	17.3640068	32.790440	1.076679e-08	Yes
'total sulfur dioxide'	1	35.200077	35.2000769	66.472331	4.290312e-16	Yes
type	1	4.501858	4.5018577	8.501373	3.562042e-03	Yes
pH	1	2.951778	2.9517778	5.574180	1.825927e-02	Yes
Residuals	5948	3149.732426	0.5295448	NA	NA	NA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	significance
alcohol	1	201.450431	201.4504309	542.370805	2.036395e-100	Yes
sulphates	1	60.223809	60.2238093	162.142299	4.528050e-35	Yes
'volatile acidity'	1	18.575438	18.5754375	50.011186	2.499753e-12	Yes
'total sulfur dioxide'	1	6.701440	6.7014404	18.042481	2.315482e-05	Yes
pH	1	3.605432	3.6054322	9.707009	1.876183e-03	Yes
'citric acid'	1	3.981337	3.9813371	10.719069	1.088513e-03	Yes
Residuals	1289	478.767668	0.3714257	NA	NA	NA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	significance
alcohol	1	672.707579	672.7075788	1196.361071	1.642458e-233	Yes
'volatile acidity'	1	157.045850	157.0458504	279.294522	6.200790e-61	Yes
'residual sugar'	1	74.574817	74.5748167	132.625840	2.798713e-30	Yes
'free sulfur dioxide'	1	38.946993	38.9469934	69.264370	1.119684e-16	Yes
sulphates	1	11.640369	11.6403694	20.701543	5.503910e-06	Yes
pH	1	7.576200	7.5761996	13.473715	2.446409e-04	Yes
'fixed acidity'	1	5.155755	5.1557553	9.169132	2.474807e-03	Yes
Residuals	4653	2616.357586	0.5622948	NA	NA	NA

Figura 9: Analisis ANOVA de los modelos del *general* dataset, *red* dataset y *white* dataset

5. Análisis de Componentes Principales (PCA)

Selección del número de componentes: Se utilizaron múltiples criterios para determinar el número óptimo de componentes: scree plot porcentual con porcentaje de aportación de cada componente, scree plot con eigenvalues y línea horizontal en 1 (regla de Kaiser), procedimiento de análisis paralelo de Horn, y función nScree. Los cuatro métodos convergieron en la selección de 4 componentes principales para los tres datasets.

Interpretación de Componentes- Dataset General:

PC1 (varianzaexplicada): Dominado por dióxido de azufre (libre y total), cloruros y acidez volátil. Representa el 'perfil de conservación' del vino.

PC2: Dominado por densidad, alcohol y azúcar residual. Representa el 'cuerpo' del vino.

PC3: Dominado por acidez fija, ácido cítrico y pH. Representa el 'perfil de acidez' del vino.

PC4: Dominado por sulfatos, calidad y pH. Representa características complementarias de frescura y percepción de calidad

Interpretación de Componentes- Dataset Red (Vinos Tintos):

PC1: Similar al PC3 del dataset general, dominado por acidez fija, ácido cítrico, pH y densidad. Representa el 'perfil de acidez' específico de vinos tintos.

PC2: Dominado por densidad, alcohol, calidad y cloruros. Representa la 'cuerpo y calidad' del vino tinto.

PC3: Dominado por dióxido de azufre (libre y total). Representa el 'contenido sulfúrico' del vino tinto.

PC4: Similar al PC4 del dataset general, dominado por sulfatos, azúcar residual y pH.

Interpretación de Componentes- Dataset White (Vinos Blancos):

PC1: Similar al PC2 del dataset general, dominado por densidad, alcohol, azúcar residual y dióxido de azufre total. Representa el 'cuerpo' característico de vinos blancos.

PC2: Similar al PC3 del dataset general, dominado por acidez fija, ácido cítrico y pH. Representa el 'perfil de acidez' de vinos blancos.

PC3: Dominado por dióxido de azufre libre, calidad, acidez volátil y ácido cítrico.

PC4: Dominado por sulfatos, acidez volátil, cloruros y dióxido de azufre libre




Figura 10: Scree plots percentuales de *general* dataset, *red* dataset y *white* dataset







Figura 11: Scree plots con autovalores y purebas para escoger no. componentes de *general* dataset, *red* dataset y *white* dataset

	PC1	PC2	PC3	PC4
<i>fixed acidity</i>	-0.270494626223958	-0.203780434960143	-0.533229367012903	0.0809790096448826
<i>volatile acidity</i>	-0.396315341069109	-0.0554860372346399	0.234573541242664	0.117210372317431
<i>citric acid</i>	0.147037931343929	-0.114282477927954	-0.600386923385959	-0.111490855189694
<i>residual sugar</i>	0.267702251267979	-0.387283585934528	0.0570358483237917	-0.107688000610594
<i>chlorides</i>	-0.414356427552831	-0.250353838877846	0.0188509533970499	-0.0814100956949489
<i>free sulfur dioxide</i>	0.393464674925842	-0.177028910299214	0.122648385719549	-0.282299392827914
<i>total sulfur dioxide</i>	0.435054569146966	-0.213189140670959	0.126179010530277	-0.113172386371306
<i>density</i>	-0.152020645147188	-0.547724533057302	-0.00368372679785468	-0.161244407818352
<i>pH</i>	-0.205903612554148	0.133009253675476	0.410776120130573	-0.474262049193839
<i>sulphates</i>	-0.288761927350948	-0.0478188290283669	-0.123456886291717	-0.595591759058555
<i>alcohol</i>	0.00375496932245713	0.504269096608167	-0.174441316119467	-0.0814467566151728
<i>quality</i>	0.108627145451923	0.280378843712143	-0.226236726063756	-0.494227988344281

	PC1	PC2	PC3	PC4
<i>fixed acidity</i>	0.525086053687676	0.0678417686609312	-0.068391943498631	0.067529812768069
<i>volatile acidity</i>	-0.264989564070983	0.344557411752098	-0.188056990799762	-0.298160320012901
<i>citric acid</i>	0.480580197147521	-0.120624563866768	0.137411749348767	0.19118528390119
<i>residual sugar</i>	0.144547157867339	0.0728858382720853	0.267319724207279	-0.594833928749467
<i>chlorides</i>	0.150045473834265	0.339195248677788	-0.058730132273009	-0.28153010751338
<i>free sulfur dioxide</i>	-0.12086853738972	0.0822786403591008	0.65930970914119	0.0814433353566792
<i>total sulfur dioxide</i>	-0.0714202200234631	0.22965341009087	0.635153514971318	0.121135223195825
<i>density</i>	0.37293267499218	0.358961858823566	-0.0396464259785834	-0.282571804093359
<i>pH</i>	-0.41366740003597	-0.102515069460743	0.00410324976013658	-0.340240659769194
<i>sulphates</i>	0.188800787832606	-0.296569652424137	0.137972860250433	-0.381131373295984
<i>alcohol</i>	-0.0221482401761406	-0.500721398469695	0.0614846182595133	-0.153437695822995
<i>quality</i>	0.116852407261319	-0.451899037696094	0.0604254390280685	-0.22623039260339

	PC1	PC2	PC3	PC4
<i>fixed acidity</i>	0.138275434234077	-0.596736070885325	-0.0918403139915675	-0.104524250767866
<i>volatile acidity</i>	-0.00250182185223968	0.0766808277448987	0.469733004030743	0.349732971597039
<i>citric acid</i>	0.107147477335449	-0.348973546172809	-0.435251971509375	-0.205646180498759
<i>residual sugar</i>	0.397390207585406	0.00972494671080205	-0.0413874088297787	0.325514319828134
<i>chlorides</i>	0.300963934272397	0.0661751876930527	0.226083966633877	-0.32732425582456
<i>free sulfur dioxide</i>	0.27585904251104	0.254652345185664	-0.385769217324169	0.335996494728307
<i>total sulfur dioxide</i>	0.383797995032026	0.220333943255378	-0.178510415247414	0.154520817000739
<i>density</i>	0.495923413805943	-0.00102935101228899	0.0306307152913563	-0.0117545276485901
<i>pH</i>	-0.103337117846362	0.579564988299921	-0.0301977891233063	-0.271300236896458
<i>sulphates</i>	0.0443110240329608	0.231917502189995	-0.263042562310243	-0.537148969702104
<i>alcohol</i>	-0.441474660236116	-0.0238685144300575	-0.16369107042614	0.197077025793594
<i>quality</i>	-0.20979454083714	0.0901272094806973	-0.500124929063668	0.271089934518119






Figura 13: Bibiplots de sample de *general* dataset, *red* dataset y *white* dataset

6. Analisis de Clustering

Dendograma y k-means

Se aplicó análisis de clustering tanto jerárquico como no jerárquico (k-means) a cada dataset, utilizando únicamente las variables que resultaron significativas en los modelos de regresión finales.

Se utilizó la función NbClust con los datos muestreados ($n = 1000$) para determinar el número óptimo de clusters recomendado. Los resultados fueron: 2 clusters para el dataset general, 4 clusters para el dataset red, y 3 clusters para el dataset white.








Figura 16: Resultados de Kmenans para *general* dataset, *red* dataset y *white* dataset



lgarciaorozco6@gmail.com

Gracias por su tiempo.